



Agente IA vs. Agente Humano en gestión de cobranza

Qué dicen 100 llamadas grabadas sobre la viabilidad de automatizar la gestión de cartera

● Sergio Felipe · Prueba técnica Data Scientist / Data Analyst Junior · 16 de septiembre de 2026

github.com/Sergiofbc/Audio-Data-Analysis

100

llamadas

6.35 h

de audio

28

variables

5

capas

CONTEXTO

Dos formas de hacer el mismo trabajo, y grabaciones de ambas

La operación de cobranza convive hoy con dos modalidades: agentes humanos que llaman al cliente y agentes de IA que ejecutan el mismo tipo de gestión. De ambas quedan grabaciones.

Esas grabaciones son el único registro de lo que realmente pasa en la llamada: qué se ofrece, qué objeta el cliente, cómo termina. Nada de eso está estructurado en ningún sistema.

-  **Llamadas grabadas**
50 humanas · 50 de IA
-  **Audio crudo**
sin transcribir, sin etiquetar
-  **Dataset estructurado**
28 variables por llamada
-  **Evidencia de negocio**
para decidir sobre automatización

La pregunta que hay que responder

¿Puede la información contenida en las conversaciones permitirnos evaluar la viabilidad de automatizar parte de la gestión de cobranza que hoy realizan agentes humanos?

Preguntas de partida

- ¿Qué caracteriza a una gestión exitosa?
- ¿Qué variables se pueden extraer de una conversación?
- ¿Existen diferencias reales entre ambos grupos?
- ¿Son comparables las dos muestras?
- ¿Qué implicaciones tiene para el costo de la operación?

Del audio crudo a una decisión sustentada

Objetivo general. Analizar las conversaciones de cobranza de agentes humanos y de IA, identificando variables de gestión y evaluando su comparabilidad, para generar evidencia que apoye la decisión sobre automatización.

1

Comprender el contexto de las llamadas antes de automatizar nada

2

Definir las variables que caracterizan una gestión

3

Evaluar y elegir el motor de transcripción con un benchmark

4

Automatizar la extracción de variables sobre las 100 llamadas

5

Comparar estadísticamente los dos grupos

6

Identificar los límites de comparabilidad de las muestras

100 llamadas, dos poblaciones distintas desde el origen

50 + 50

llamadas

humanas y de IA,
de campañas distintas

6.35 h

de audio

mediana de 171 s (humano)
y 149 s (IA)

6.1 %

censurado

datos personales tapados
con un pitido

0

metadatos

ni campaña, ni resultado,
ni tipo de gestión

Lo que el brief advierte desde el principio

Los audios provienen de distintas campañas y momentos de gestión. No es un experimento controlado: no es el mismo caso repartido al azar entre un agente humano y uno de IA, son poblaciones de llamadas distintas desde el origen. Eso hay que asumirlo antes de comparar nada — y resultó ser el hallazgo que reorientó todo el análisis.

CRISP-DM, pero recorrido en espiral

El proyecto no avanzó en línea recta. La evaluación de resultados cambió la comprensión del problema y obligó a volver al principio con una pregunta distinta.



La evaluación devolvió el proyecto a la comprensión del negocio. Al comparar los grupos apareció un problema de composición de muestra que invalidaba la pregunta original — y obligó a reformularla en vez de responderla mal.

Primero escuché; después decidí qué medir

No quise definir las variables desde una perspectiva técnica. Antes de escribir código escuché una muestra de llamadas completas para entender qué es una «gestión» dentro del negocio: cómo abre el agente, qué ofrece, qué objeta el cliente, cómo termina.

“Primero entendí el problema; después decidí qué datos necesitaba extraer.”

De esa escucha salieron las categorías de variables:

- Características y tipo de la gestión
- Propuesta económica ofrecida
- Objeciones del cliente y respuesta del agente
- Resultado y motivo de cierre de la llamada
- Tono del cliente y adaptación del agente

Lo que la escucha reveló

● No todas las llamadas son lo mismo

unas negocian un descuento nuevo; otras solo recuerdan una cuota ya pactada

● Los datos sensibles están tapados

un pitido cubre nombres, cédulas y montos

● El éxito no es una sola cosa

cerrar a la primera, cerrar tras negociar, o dejar una fecha acordada

● Hay llamadas que ni siquiera arrancan

no contesta el titular, o la línea se cae

Perfilar el audio antes de gastar un crédito de transcripción

Antes de transcribir medí los 100 audios en crudo: formato, ruido, actividad de voz y censura. Tres decisiones del pipeline dependían de eso.

8 kHz • mono

Formato idéntico en 100/100

Un solo canal: no hay una pista por interlocutor, así que la diarización deja de ser opcional. Sobre 3 400 Hz vive el 0.03 % de la energía — pedir más calidad no recuperaría nada.

1 000.0 Hz

El pitido de censura

Tono sintético a -15.0 dBFS, amplitud plana. Detectado con reglas, sin modelos: 1 623 pitidos que tapan el 6.1 % del corpus. Se cruza con la transcripción por marca de tiempo.

12 dB

de diferencia en ruido

Los audios humanos tienen peor relación señal/ruido que los de IA (41.5 vs 53.8 dB). 9 de 50 humanos bajan de 35 dB; ninguno de IA. El ruido no se reparte por igual.

Consecuencia metodológica. Si el motor de transcripción falla más donde hay ruido, fallará sistemáticamente más en el grupo humano. La calidad del audio entra al estudio como variable de control, no como nota al pie.

El motor se eligió con una prueba, no con un folleto

Mismos 6 audios (el más corto, el mediano y el más largo de cada grupo), misma configuración, dos motores. Google Chirp 3 quedó descartado antes de probarlo: no entrega marcas de tiempo por palabra ni variante de español latino.

	Deepgram Nova-3	ElevenLabs Scribe v2
Hablantes detectados (esperado: 2)	2 de 6 casos	6 de 6 casos
Confianza media	0.885 – 0.978	0.963 – 0.985
Palabras de baja confianza	1.3 – 10.4 %	1.1 – 3.2 %
Peor caso (audio humano largo)	3 hablantes • 10.4 %	2 hablantes • 3.2 %


Gana ElevenLabs

El criterio que decide no es la confianza: es la diarización. Deepgram partió al mismo hablante en tres voces en los audios ruidosos. Sin dos hablantes bien separados no hay forma de saber quién ofreció y quién aceptó.

US\$ 1.40

costo total de transcribir las 6.35 horas del corpus completo. El precio nunca fue el criterio de selección — por ese margen se pueden correr los dos motores.

De 100 archivos de audio a una tabla analizable



Las variables no las eligió el modelo. Se definieron en la escucha manual; la IA solo se usó para escalar su extracción a las 100 llamadas bajo un esquema fijo de 28 campos.

Validación manual


25 de las 100 filas revisadas a mano contra la transcripción (las 10 de confianza baja + 15 al azar): 23 correctas, 2 errores encontrados y corregidos en el dataset.

Las 5 capas de análisis

- 1 Negocio.** ¿la llamada consigue una gestión exitosa?
- 2 Negociación.** ¿con qué propuesta económica se consigue?
- 3 Objeciones.** ¿qué objeciones resuelve cada agente?
- 4 Conducta.** ¿interrumpe, monopoliza, deja silencios?
- 5 Sentimiento.** tono del cliente (exploratorio)

Los dos grupos no están haciendo el mismo trabajo

Al extraer el tipo de gestión de cada llamada apareció el problema: la IA hace casi solo negociación nueva; más de la mitad del tiempo del humano se va en seguimiento de acuerdos que ya existen.




0

Llamadas de seguimiento en el grupo de IA

La comparación «todo contra todo» estaba midiendo dos trabajos distintos.


La mitad de la brecha era composición de muestra

Tasa de cierre — todas las llamadas



Fisher exact $p = 0.0018$ • diferencia significativa

Tasa de cierre — solo negociación nueva (comparable)



Fisher exact $p = 0.37$ • deja de ser significativa • $n = 18$ vs 37

Qué significa

Comparando el mismo tipo de gestión, la ventaja del humano se reduce a la mitad y deja de ser estadísticamente sustentable. Reportar el 54 % contra 22 % sin ese ajuste sobreestima la distancia real entre los agentes.

92 % vs 68 %

contacto efectivo: el humano logra hablar con quien decide mucho más seguido

1 de cada 4 llamadas de IA se pierde por falla técnica

13 / 50

llamadas de IA caídas

contra 1 de 50 en humano:
20 veces más

10 de 13

ya tenían contacto real

el cliente estaba al teléfono
cuando se cayó la línea

\$22.9 M

COP sobre la mesa

deuda ya mencionada en las
llamadas que se cortaron

Esto no es una derrota de negociación: es infraestructura.

El cliente no rechazó la oferta ni colgó: la llamada se cayó, el IVR no respondió o el bot se quedó mudo. Es el hallazgo más limpio del análisis — no depende de ningún ajuste por tipo de gestión — y también el más barato de corregir: arreglarlo cierra media brecha sin tocar una línea del guion de negociación.

Cuando la IA cierra, no deja más plata sobre la mesa

% de la deuda original recuperado, en llamadas que sí cerraron



Mann-Whitney U $p = 0.50$ • sin diferencia significativa • $n = 8$ vs 10

Descuento mediano ofrecido sobre la deuda



humano $n = 5$ • IA $n = 31$ • muestras muy dispares, no se contrasta

Lo que valida

Ningún agente negocia descuentos más generosos que el otro. El argumento económico de automatizar no se debilita por la vía de la propuesta: cuando la IA llega a cerrar, cierra en condiciones equivalentes.

La honestidad del dato

Son 8 y 10 casos. Con esa muestra no se puede afirmar que sean iguales, solo que no hay evidencia de que sean distintos. Es una ausencia de diferencia, no una demostración de igualdad.

La IA sostiene el guion; el humano sostiene la conversación

Estas métricas se calculan sobre los 100 audios crudos —no dependen de la transcripción ni del tipo de gestión—, así que ningún artefacto de composición las afecta.

	Humano	IA		
Duración del turno de habla	0.59 s	0.78 s	$p < 0.0001$	68 % vs 35 % el agente se adapta a lo que dice el cliente
Turnos por minuto	43.3	38.6	$p = 0.009$	
Habla solapada (interrumpe)	11.4 %	7.3 %	$p < 0.0001$	3x más seguido empeora el tono del cliente con la IA
Tiempo de la llamada con voz	76.9 %	68.0 %	$p < 0.0001$	

Consistente pero rígida: la IA nunca se sale del guion — lo que la hace predecible, y también incapaz de improvisar ante una objeción.

La capa de sentimiento (68 % / 35 % y el cambio de tono) es exploratoria: menor rigor que las capas 1 a 4, a propósito.

La pregunta que sí se puede responder con estos datos

Pregunta inicial

¿Son comparables las gestiones de humanos y de IA, y hay diferencias en sus resultados?



Lo que encontré

La composición de las muestras no permite una comparación directa: son dos trabajos distintos, no dos formas de hacer el mismo.



Pregunta reformulada

¿Qué parte de la operación humana actual puede automatizarse con la evidencia disponible, y qué habría que arreglar primero?

No se abandonó el análisis.

Se cambió la pregunta por una que los datos sí pueden sostener — y que además es más útil para decidir.

Esa es la diferencia entre ejecutar un análisis y hacer análisis.

Tres movimientos, en orden de retorno

01

RÁPIDO Y BARATO

Arreglar la caída técnica

26 % de las llamadas de IA se pierden por falla, no por rechazo. Es la mayor ganancia disponible sin tocar el guion de negociación, y no requiere ciencia de datos: requiere ingeniería de telefonía.

02

YA VALIDADO

El argumento de costo se sostiene

Cuando la IA cierra, recupera una proporción equivalente de la deuda (95.8 % vs 86.7 %, $p = 0.50$). La propuesta económica no es el punto débil de la automatización.

03

LA OPORTUNIDAD NATURAL

Extender el alcance al seguimiento

El seguimiento humano (54 % de sus llamadas) no negocia descuento en ningún caso, dura 43 % menos (161 s vs 281 s) y cierra el 70 % de las veces. Es guion fijo — justo lo que la IA ya ejecuta bien.

Una advertencia sobre el modelo de costos

Crearé AI factura como Banker-as-a-Service: implementación más tarifa mensual, por cuenta procesada o por comisión sobre recaudo. El seguimiento de hoy ya recauda al 70 % con un costo esencialmente fijo (el agente humano). Migrarlo a IA bajo comisión sobre recaudo significa empezar a pagar variable sobre plata que hoy se recupera casi gratis; bajo cuenta procesada la cuenta es distinta. El ahorro que este análisis sí valida es sobre negociación nueva — sobre seguimiento, el modelo de costos todavía no se ha cotizado.

Lo que este análisis no puede afirmar, y qué haría falta

Limitaciones

- No es un experimento controlado: las muestras vienen de campañas y momentos distintos.
- Submuestras pequeñas en la capa de negociación (8 y 10 casos que cierran).
- El 6.1 % del audio está censurado; parte del contexto se pierde por diseño.
- La extracción de variables depende de un LLM: auditada sobre el 25 %, no sobre el 100 %.
- La atribución agente/cliente la hereda de la diarización, no de un campo estructurado.
- La capa de sentimiento es exploratoria y no sostiene conclusiones por sí sola.

Próximos pasos

Datos

Muestra emparejada: mismo tipo de gestión y misma campaña en ambos grupos.

Modelo

Medir precisión y exhaustividad de la extracción contra un etiquetado humano completo.

Análisis

Estratificar o emparejar por tipo de gestión y repetir los contrastes.

Negocio

Cotizar el modelo de costos real y construir el escenario de ROI por tipo de gestión.

El resultado no fue quién gana, sino cuándo comparar

El hallazgo principal no fue determinar si la IA rinde más o menos que un agente humano, sino identificar bajo qué condiciones esa comparación es válida — y cómo convertir conversaciones grabadas en evidencia utilizable para decidir sobre automatización.

Audio



Datos



Evidencia



Decisión

Media brecha

era composición de muestra, no desempeño

1 de cada 4

llamadas de IA se pierde por falla técnica

El seguimiento

es la extensión de alcance más natural

Las 28 variables extraídas por llamada

● **Identificación**

- file**
UUID del audio
- grupo**
humano | ia
- tipo_gestion**
nueva_oferta | seguimiento_o_renegociacion | otro
- contacto_efectivo**
¿se habla con quien puede decidir?
- de_donde_llaman**
entidad que menciona el agente
- origen_deuda**
producto que originó la deuda

● **Propuesta económica**

- monto_total_actual_cop**
deuda vigente
- descuento_pct**
descuento ofrecido
- descuento_monto_cop**
descuento en pesos
- valor_a_pagar_cop**
valor pactado
- n_cuotas**
número de cuotas
- fecha_max_pago**
fecha límite ofrecida
- fecha_pago_acordada**
fecha que acepta el cliente
- comparte_medios_pago**
¿se explica cómo pagar?

● **Negociación y cierre**

- cliente_puede_pagar**
si | no | tal_vez | no_queda_claro
- objecion_cliente**
¿hay objeción?
- tipo_objecion**
naturaleza de la objeción
- alternativa_propuesta**
contraoferta del agente
- resultado_llamada**
7 categorías de desenlace
- caso_exito**
recalculado desde resultado_llamada
- quien_corta_la_llamada**
agente | cliente | técnico
- motivo_fin_llamada**
por qué termina

● **Control y tono**

- confianza_extraccion**
alta | media | baja
- notas**
observación libre
- tono_inicial_cliente**
al abrir la llamada
- tono_final_cliente**
al cerrar
- cambio_tono**
mejora | igual | empeora
- agente_se_adapta**
¿reacciona a lo que dice el cliente?

caso_exito no se toma del extractor: se recalcula de forma determinista desde resultado_llamada al consolidar, para que la variable dependiente no dependa de un juicio del modelo. • Esquema y prompt en analisis/src/extract_variables.py